FIT5196 数据整理单元

评估 1：探索性数据分析 (EDA)

截止日期：2025 年 9 月 14 日 23:55
权重：35%

评估概述

🎯 主要目标

- **数据熟悉化**：深入理解数据集结构、内容和质量
- **数据质量评估**：识别缺失值、重复值、无效值或不一致
- **可视化探索**：使用可视化技术发现隐藏结构和模式
- **研究洞察生成**：将 EDA 发现转化为潜在的机器学习研究问题

📊 项目类型

- 小组评估（数据整理单元）

输入数据文件

📂 数据源

- **Group<组号>.xml** - Flickr 照片数据
- **Group<组号>.json** - Flickr 照片数据
- 每条照片记录包含**18 个属性**

🔍 需要检查的属性

- 请参考示例输入文件了解所有可用属性
- 确保使用正确的输入数据文件（错误文件会导致零分）

第一阶段：数据加载、解析和合并

📥 数据加载任务

- 使用 Python 代码从两个文件加载数据
- 将加载的数据转换为适合操作的对象
- 检查两个文件数据的结构和模式
- 使用适当方法合并数据

🧹 数据清理要求

- **文本处理（5 个属性）**： Title, City, Country, Tags, Description
  - 转换为小写（'NaN'除外）
  - 移除 XML/JSON 标签和表情符号
  - 只保留有效 UTF-8 字符
  - 完全移除非英文字符

数据清理技术细节

🔧 技术要求

- **仅允许使用正则表达式**进行文本处理
- 所有空值必须表示为'NaN'
- 保留数字和非英语语言内容（需要理由和说明）
- 输出格式：`Group<组号>_dataset.csv`

⚠️ 重要提醒

- 必须具有与示例输出文件完全相同的属性
- 代码必须可测试（使用测试数据集验证）
- 解决方案必须可重现，无错误

第二阶段：探索性数据分析 (EDA)

🎯 EDA 目标

- 深入了解数据集
- 为后续决策提供信息（预处理、模型设计、假设生成）

📊 分析任务

1. **数据集结构分析**：整体维度和结构
2. **单变量分析**：单个变量的分布
3. **双变量分析**：变量对之间的关系
4. **多变量分析**：复杂关系识别
5. **数据质量评估**：缺失值、重复值、异常值
6. **可视化**：创建适当的图表和图形

第三阶段：洞察和研究问题

💡 关键洞察要求

- **至少 10 个关键洞察**来自 EDA 发现
- 必须是数据驱动和基于证据的
- 包括相应的可视化

🤖 机器学习研究问题要求

- **至少 5 个高质量 ML 问题**
- 必须明确定义输入特征和输出变量

ML 问题类型和质量标准

🎯 可考虑的 ML 问题类型

- **监督学习**：分类、回归
- **无监督学习**：聚类、降维
- **半监督学习**
- **其他**：时间序列分析、序列模式检测、异常检测

✅ 质量评估标准

- 数据驱动（有 EDA 证据支持）
- 明确定义（具体输入/输出变量）
- 有意义的价值生成
- 适当的 ML 技术选择
- 可衡量的成功标准

📋 提交文件清单

1. EDA 方法论 (35%)

- `Group<组号>_solution.ipynb` - EDA 过程笔记本
- `Group<组号>_solution.py` - 用于抄袭检查的 Python 代码
- `Group<组号>_dataset.csv` - 合并数据集

2. EDA 报告 (50%)

- `Group<组号>_EDA.pdf` - 综合 EDA 报告

3. 视频演示 (10%)

- `Group<组号>_presentation.mp4` - 6-10 分钟演示

4. AI 工具文档 (5%)

- `Group<组号>_AI_declaration.pdf` - AI 工具声明表
- `Group<组号>_AI_record.pdf` - AI 对话记录

提交格式要求

📦 文件打包

1. **Group<组号>_A1.zip** 包含 6 个文件：
   - 解决方案笔记本 (.ipynb)
   - Python 代码 (.py)
   - 数据集 (.csv)
   - 视频演示 (.mp4)
   - AI 声明 (.pdf)
   - AI 记录 (.pdf)

2. **Group<组号>_EDA.pdf** - 单独文件（不在 zip 内）

⚠️ 重要提醒

- **5%扣分**：如果 EDA 报告放在 zip 文件内
- 两个小组成员都必须点击 Moodle 上的"提交"按钮
- 严格遵循文件命名标准

时间安排（从 8 月 24 日开始）

📅 阶段时间表

阶段 1：数据处理 (8 月 24 日-9 月 1 日) - 关键路径

- 加载和解析 XML/JSON 文件
- 实现数据清理和正则表达式
- 合并数据集
- 生成最终 CSV 输出

阶段 2：EDA 实施 (9 月 2 日-8 日) - 依赖阶段 1

- 进行综合分析
- 创建可视化
- 记录发现和洞察

时间安排（续）

📅 阶段时间表

阶段 3：研究问题 (9 月 9 日-11 日) - 依赖阶段 2

- 制定 ML 研究问题
- 确保质量和可行性
- 链接到 EDA 证据

阶段 4：文档和演示 (9 月 12 日-14 日) - 依赖阶段 3

- 撰写 EDA 报告
- 创建视频演示
- 准备 AI 文档
- 最终审查和提交

最终截止日期：9 月 14 日 23:55

🔗 任务依赖关系

必须首先执行（无依赖）：

1. 数据加载和解析 - 立即开始
2. 数据模式分析 - 与加载并行

无法开始直到数据加载完成：

3. 数据清理，转换，合并

无法开始直到合并完成：

5. 数据集生成

无法开始直到 EDA 完成：

7. 洞察生成
8. ML 研究问题

无法开始直到研究问题完成：

9. 报告写作
10. 视频演示

最终任务（所有依赖满足）：

11. AI 文档（可随时完成）
12. 提交准备

成功标准

🎯 技术成功

- 清洁、合并的数据集，格式正确
- 可重现的代码，通过测试
- 全面覆盖所有要求的 EDA

📊 分析成功

- 至少 10 个有意义的洞察
- 至少 5 个高质量 ML 问题

风险缓解

⚠️ 常见陷阱避免

- 使用错误的输入数据文件（导致零分）
- 不完整的数据清理（仅限正则表达式）
- 洞察或 ML 问题不足
- 可视化质量差
- 缺少 AI 声明（障碍要求）
- 文件命名或提交格式不正确

下一步行动

🚀 今天就开始

立即执行：

1. 打开 `GroupXX.json` 和 `GroupXX.xml` 文件
2. 开始加载和检查数据结构
3. 理解 18 个属性的含义
4. 规划数据清理策略

本周目标：

- 完成数据加载和解析
- 理解数据结构和模式
- 开始实施数据清理

💡 记住

数据处理阶段是关键路径 - 如果这个阶段延迟，整个项目都会受影响！

问题和讨论

🤔 需要澄清的问题

- 数据文件的具体结构
- 正则表达式的具体要求
- 可视化类型的选择
- 报告格式的详细要求

谢谢！

祝你们项目成功！ 🚀