FIT5196 Data Wrangling

软知识 + 硬知识辅导

课程安排

Week	主题
1	Introduction to Data Wrangling
2	Data Wrangling Process & Tasks
3	Regular Expression
4-5	EDA / Data Discovery / Collection
6	Data Structuring
7-11	Quality, Cleaning, Transformation, Enrichment, Validation
12	Advanced Data Wrangling

作业与时间

Assessment 总表

项目	权重	内容	截止时间	形式
Quiz 1	10%	Applied session MCQ	Week 6	个人、线下
Quiz 2	10%	Applied session MCQ	Week 12	个人、线下
Assessment 1	35%	Coding + Report + Demo Video	Week 7 周四 23:55	小组
Assessment 2	40%	Coding + Report	Week 12 周四 23:55	小组
Presentation	未单独列权重	课堂展示	Week 15 周一 / 周二	小组
In-class Participation	5%	课堂活动	若干周 seminar	个人

Assessment 1

- EDA

- 读取和提取数据
- 做基础预处理
- 做 exploratory data analysis
- 使用合适的可视化
- 总结 raw / processed data 的发现

Assessment 2

- PARSING, CLEANSING, INTEGRATING

- 检查并审计 parsed data
- 识别 lexical errors / irregularities
- 处理 duplication / inconsistency
- 修复并整合多源数据

Quiz 和 Group Assessment 规则

- `Quiz 1` 覆盖 Week 1-6，`Quiz 2` 覆盖 Week 7-12
- 每次 quiz `30 minutes`
- 必须 `in-person` 完成 applied session quiz
- quiz 是个人作业，不允许 collaboration，不应使用 AI
- quiz 会使用 `Safe Exam Browser`
- in-class participation 也是跟 seminar 时段绑定的
- `Assessment 1/2` 是 group work，通常没有 2-day short extension
- presentation 在 `Week 15`，而且有 hurdle 要求

你需要尽早掌握什么

- `Python` 基础：变量、list、dict、for loop、function
- `Jupyter Notebook`：写代码、写 markdown、记录分析过程
- `pandas` 基础操作：读取、查看和简单处理数据
- 数据清洗思路：缺失值、异常值、重复、不一致
- 基础数据可视化
- 读懂常见数据格式：`CSV`、`JSON`、`HTML/XML`

软知识：定义、目标与挑战

Data Wrangling 是把原始数据变成可分析数据的过程。

`Raw Data -> Clean / Tidy Data -> Actionable Insights`

不要误解成	原因
只是可视化	可视化只是后续分析的一部分
只是数据清洗	清洗只是流程中的一环
只是机器学习	wrangling 是分析前准备工作

真题讲解

What is the primary purpose of Data Wrangling?

选项	内容
a	To analyze complex data types
b	To ensure data privacy
c	To acquire, clean, structure, and enrich raw data for analysis
d	To visualize data trends

答案： `c`
讲解： 题干问的是 primary purpose，所以选最完整定义。privacy、visualization 都相关，但不是核心定义。

Data Wrangling 的主要目标

目标	含义
Improve quality	提高数据质量
Simplify access	让数据更容易获取和使用
Support integration	让多源数据更容易整合
Reduce complexity	降低处理难度
Improve efficiency	提高分析效率
Support decisions	支持后续决策

真题演练

Which of the following are common goals of data wrangling?

`Select all that apply`

选项	内容
a	Increasing data complexity
b	Ignoring data inconsistencies
c	Improving data quality
d	Facilitating easier access to data

答案： `c, d`

讲解： 看到 goals 先排除反项。increase complexity、ignore inconsistencies 都是典型干扰项。

为什么一定要做 Wrangling

原始数据问题	会导致什么
Missing values	结果不稳定、信息不完整
Wrong values	结论错误
Duplicate records	统计被放大
Inconsistent formats	难以合并和比较
Complex structures	无法直接分析

现实中的数据来源

- 表格：CSV、Excel、数据库导出
- 半结构化：JSON、XML、HTML
- 文本：日志、评论、报告
- 图像与传感器：医疗影像、wearable devices
- 开放与平台数据：UCI、Wikipedia、social media

重点不是来源越多越好，而是 accessibility、relevance、quality、cost 是否合适。

Wrangling的挑战

挑战	具体表现
Volume and scalability	数据量大，传统工具顶不住
Data quality	缺失、错误、异常、重复
Diverse sources	来源多、结构杂
Lack of standardization	日期、货币、命名规则不统一
Time-consuming	大量时间花在清洗和整理
Skills and tools	要会 Python、统计、数据库、NLP
Privacy and security	敏感数据要合规处理

真题演练

A major challenge in data wrangling is:

选项	内容
a	Avoiding data standardization
b	Maintaining low data quality
c	Data privacy and security
d	Handling small volumes of data

答案： `c`

讲解： Week 1 的 challenge 重点是 volume、quality、diversity、standardization、privacy/security。small volumes 不是挑战。

工具链

工具	用途
Python 3	主语言
Jupyter Notebook	代码、文字、输出放一起
Google Colab	免安装练习环境
Anaconda	本地数据科学环境
VS Code / PyCharm	后续脚本开发

常见库	用途
`pandas`	表格数据处理
`numpy`	数值计算
`scipy`	科学计算
`scikit-learn`	数据分析与建模工具
`BeautifulSoup`	HTML/XML 解析
`NLTK`	文本处理

软知识：流程与判断

Data Wrangling 的八大步骤

步骤	含义
Discovery	发现数据
Collection	收集数据
Pre-processing	预处理
Cleaning	数据清洗
Transformation	数据转换
Enrichment	数据增强 / 补充信息
Validation	数据验证
Storing	数据存储

真题演练

Which of the following are considered tasks in the Data Wrangling process?

`Select all that apply`

选项	内容
a	Data Modification
b	Data Storing
c	Data Validation
d	Data Presentation
e	Data Cleaning

答案： `b, c, e`

讲解： 看到 pipeline 里的标准任务就选；presentation 不是本课程定义的 wrangling task，modification 过于模糊，不是课上标准标签。

1. Discovery

- 先确认要解决什么分析问题
- 找可能的数据来源，不是立刻下载
- 评估来源是否可访问、相关、可用
- 先看 suitability / availability / quality

医疗案例:

- EHR / 电子病历
- admission / discharge records
- insurance claims
- wearable device data
- patient histories / medications

关键词：identify sources, accessibility, suitability, quality

真题讲解

Which phase comes immediately after data discovery?

选项	内容
a	Data storage
b	Data collection
c	Data cleaning
d	Data analysis

答案： `b`

讲解： Week 2 八步流程必须背顺序。最常见考法就是问前后相邻步骤。

2. Collection

收集前要想清楚	为什么
objective	你到底要回答什么问题
data requirements	需要哪些字段和粒度
source / format	从哪里拿、是什么格式
quality / volume	数据够不够、质量稳不稳
ethics / privacy	合规、授权、敏感信息处理
methods / tools	API、database、spreadsheet 还是 web
timeframe / budget	时间和资源能不能支撑
documentation	后面要复现和解释过程

真题演练

Factors to consider during the data collection phase include:

`Select all that apply`

选项	内容
a	Collection method efficiency
b	Source reliability
c	Data format
d	Cost of data storage physical locations

答案： `a, b, c`

讲解： collection 阶段关注怎么收、来源靠不靠谱、格式能不能用。storage physical locations 更偏 storing，不是这里的重点。

3. Pre-processing

常见动作	说明
Subsetting	只保留相关行或列
Sampling	数据太大时抽代表性样本
Date / Numeric / Categorical formatting	统一日期格式; 小数点、千位分隔符统一; `Male/M` 统一
Unit / currency conversion	公里英里、USD/AUD 等统一
Encoding / timezone	UTF-8、时区对齐
File conversion	XML 转 CSV，JSON 转结构化表

关键词：subset、sample、format、unit、encoding、conversion

真题演练

Data standardization helps ensure data is:

选项	内容
a	In a consistent format
b	Only available in one unit of measurement
c	Inconsistent across datasets
d	Difficult to analyze

答案： `a`

讲解： standardization 的关键词是 consistent format。题里如果出现 inconsistent、difficult 这类反向措辞，通常直接排除。

4. Cleaning

- 找并修复 `missing values`
- 检查 `outliers`
- 删除或合并 `duplicate records`
- 修正 `consistency issues`
- 识别 data anomalies
- 注意 anomaly 不一定只是错误，也可能是新模式或重要信号

考试里看到 correcting inaccuracies / inconsistencies / duplicates，优先想到 cleaning。

真题演练

Data cleaning may involve:

`Select all that apply`

选项	内容
a	Correcting errors
b	Removing duplicates
c	Handling missing values
d	Introducing new errors

答案： `a, b, c`

讲解： cleaning 的典型关键词就是 correcting errors、duplicates、missing values。题里常故意放一个明显错误项来扰乱节奏。

5. Transformation

- 把数据变成更适合分析的结构或表示
- 常见于 numeric / text / image 三类数据
- 目标是让后续分析、建模、比较更稳定

Numeric 常见操作	作用
Normalization	缩放到固定范围
Standardization	调到均值 0、方差 1
Aggregation	求和、均值、分组统计
Discretization	连续值切成区间
Binning / Bucketing	分桶后变成类别

5. Transformation 还包括什么

数据类型	常见操作
Text	tokenization, stemming / lemmatization, vectorization
Image	resize, crop, normalization, colour conversion
Image augmentation	rotation, flipping, translation, noise / brightness / contrast adjustment

易混点：normalization 和 standardization 不一样；discretization 和 binning 也不要混。

真题讲解

What process involves scaling data to a small, specified range?

选项	内容
a	Diversification
b	Normalisation
c	Aggregation
d	Segmentation

答案： `b`

讲解： 如果题干强调 fixed range，例如 `0-1`，优先想到 normalization；如果强调 mean 0 / variance 1，才是 standardization。

6. Enrichment

方式	含义
Data integration	合并不同来源数据
Data augmentation	给现有记录补更多信息
Attribute enrichment	新增特征或属性
Temporal enrichment	补充时间维度
Semantic enrichment	加 metadata / tag / meaning

一句话：不是修错，而是让数据“更完整、更有上下文”。

真题演练

The goals of data enrichment include:

`Select all that apply`

选项	内容
a	Adding value to the data
b	Improving data quality
c	Enhancing data analysis capabilities
d	Simplifying data formats

答案： `a, b, c`

讲解： enrichment 是补上下文、补特征、补时间维度。simplifying formats 更像 pre-processing / transformation，不是 enrichment 核心。

7. Validation

检查项	典型问题
Accuracy	值是否反映真实世界
Consistency	同一字段规则是否统一
Completeness	关键值是否缺失
Logical integrity	年龄、日期、关系是否讲得通
Range / constraints	值域是否超界
Format validation	格式是否符合预期
Uniqueness	本应唯一的键是否重复
Cross-validation	能否用别的数据源交叉验证

真题演练

In data wrangling, data validation ensures:

`Select all that apply`

选项	内容
a	Data meets predefined standards
b	Accuracy and reliability of data
c	Data inconsistency is promoted
d	Data is in a usable format for analysis

答案： `a, b, d`

讲解： validation 是 checking，不是 fixing。它检查 standards、accuracy、usability；promoted inconsistency 显然是反项。

8. Storing

存储阶段要考虑	重点
Storage solution	database / warehouse / cloud
Schema design	查询和维护是否方便
Normalization / denormalization	完整性 vs 读取效率
Format / encoding	存储格式要一致
Security	权限、隐私、合规
Indexing / optimization	检索速度
Backup / recovery	可恢复性
Metadata / monitoring	后续治理与维护

真题演练

What aspects does Data Cataloging and Metadata Management cover?

`Select all that apply`

选项	内容
a	Usage metadata
b	Data anonymisation
c	Metadata collection
d	Data lineage documentation
e	Catalog creation

答案： `a, c, d, e`

讲解： 关键词是 metadata、lineage、catalog。anonymisation 更偏 privacy / governance，不是 cataloging 的直接定义。

用一个例子串起来

`Discovery`：找医院再入院预测相关数据源

`Collection`：确认权限、字段、格式、预算、时间

`Pre-processing`：筛时间范围、抽样、统一日期和单位

`Cleaning`：处理缺失、重复、异常和不一致

`Transformation`：聚合、标准化、把文本转成可分析形式

`Enrichment`：补保险、地理、行为或时间信息

`Validation`：检查范围、唯一性、逻辑约束

`Storing`：把结果存进可复用的数据表或仓库

硬知识

硬知识概览

- Notebook 只是载体，不是重点
- Python 基础只保留最低门槛
- 主体放在 `pandas for data wrangling`
- 重点练 DataFrame 的查看、筛选、清洗、转换
- 重点练 `loc / iloc / isna / dropna / rename / sort_values`

这一部分只高度概括 Python / Markdown，课堂主轴是 `pandas` 如何服务 data wrangling。

硬知识

Python / Markdown 只保留最低要求

模块	最少会什么
Jupyter Notebook	分清 code cell 和 markdown cell，能运行 cell
Markdown	会标题、列表、表格，能写过程说明
Python	会变量、list、dict，能读懂 `for loop` 和 `function`
练习题	`transpose_matrix` 只当基础控制流组合题

```
for item in [1, 2, 3]:
    print(item)
```

要求不是把 Python 单独讲深，而是够用就好，后面立刻进入 pandas。

硬知识：常见 pandas 操作

任务	常见写法
读 CSV	`pd.read_csv(...)`
读 Excel	`pd.read_excel(...)`
读 JSON	`pd.read_json(...)`
改列名	`df.rename(columns={'A': 'B'})`
设 index	`df.set_index('ID')`
排序	`df.sort_values(by='Name')`
指定 header	`header=`
跳过前几行	`skiprows=3`

硬知识练习顺序

顺序	对应练习
1	Creating DataFrames
2	Inspecting a DataFrame
3	Subset Observations (Rows)
4	Subset Variables (Columns)
5	Sort, Rename, Drop, Index
6	Reshaping Data
7	Summarize Data

硬知识练习顺序

顺序	对应练习
8	Handling Missing Data
9	Make New Columns
10	Group Data
11	Combine Data Sets
12	Windows
13	Plotting
14	Method Chaining

硬知识

`pandas` / `DataFrame` 基础认知

知识点	要点
导入方式	`import pandas as pd`
DataFrame	二维表格数据结构
case sensitive	`DataFrame` 不等于 `dataframe`
创建方式	list、dict、日期索引都可以建表

```
df = pd.DataFrame(
    {
        'product': ['pen', 'notebook', 'eraser'],
        'price': [2.5, 5.0, 1.2],
        'stock': [100, 50, 200],
    }
)
```

硬知识

先探索，再清洗

函数	用来干什么
`df.info()`	看列名、非空数、dtype
`df.describe()`	看数值统计摘要
`df.head()`	看前 5 行
`df.tail()`	看后 5 行
`df.shape`	看行列数
`df.columns.tolist()`	看字段列表

真实 wrangling 流程里，不是拿到数据就改；先知道结构、字段、缺失情况，再动手。

硬知识

`loc` 和 `iloc` 的本质区别

方法	按什么选
`loc`	label / 列名 / index 名称
`iloc`	integer position / 数字位置

```
ufo.loc[:, 'City':'State'].head()
ufo.iloc[1:6, 2:6]
```

考试和 applied session 都很喜欢考这个区别。一个按标签，一个按位置，不要混。

硬知识

缺失值检查的最短工作流

```
ufo.isna().sum()
ufo[ufo.isna().any(axis=1)]
ufo1 = ufo.dropna()
```

步骤	作用
`isna()` / `isnull()`	判断缺失
`.sum()`	统计每列缺失数
`.any(axis=1)`	找含缺失值的行
`dropna()`	直接删掉缺失行

硬知识

一个高频坑：空字符串不等于缺失值

`pandas` 里的 `isnull()` / `isna()` 默认只把这些视为缺失：

- `NaN`
- `None`
- `NaT`

下面这种不会自动算缺失：

```
df = pd.DataFrame({"A": ["", None, "text"]})
```

所以 data 看起来“空着”，不代表 pandas 会把它当 missing value。这个坑在 cleaning 题里很常见。

硬知识

Basic editing 不只是改值

操作	例子
新增列	`df['place'] = ''`
复制 DataFrame	`df2 = df.copy()`
删除列	`df.drop(columns=['State'])`
合并文本列	把 `City` 和 `State` 拼成 `place`

Applied session 还专门比较了 loop 写法和 pandas 写法的效率，隐含结论是：能用表格操作时，尽量别回到逐行手写循环。

真题演练

Which method is used to get a summary of a DataFrame's structure and column types?

选项	内容
a	`df.info()`
b	`df.describe()`
c	`df.overview()`
d	`df.summary()`

答案： `a`
讲解： `df.info()` 看结构和 dtype； `df.describe()` 看数值统计摘要。exam 很喜欢拿这两个放一起混淆。

真题讲解

How do you select rows 10 to 20 from a DataFrame `df`?

`Select all that apply`

选项	内容
a	`df.iloc[9:20]`
b	`df.loc[10:20]`
c	`df.locate[9:20]`
d	`df[9:20]`

答案： `a, d`

讲解： `iloc` 是位置切片，起点 0-based 且右边不含；`loc` 是标签切片，通常两端都含。`locate` 根本不是 pandas API。

真题讲解

How do you check for missing values in a DataFrame `df`?

`Select all that apply`

选项	内容
a	`df.isna()`
b	`df.has_null()`
c	`df.missing()`
d	`df.isnull()`

答案： `a, d`

讲解： `isna()` 和 `isnull()` 在 pandas 里都能用。考试常用假 API 选项混进来。

真题讲解

To drop rows with any missing values in the data frame `df`, you use:

选项	内容
a	`df.fillna()`
b	`df.dropna()`
c	`df.remove_na()`
d	`df.delete_missing()`

答案： `b`
讲解： `fillna()` 是填补，不是删除；只要题干出现 drop rows with missing values，优先锁定 `dropna()`。

学习建议

总 Checklist

能用自己的话定义 data wrangling

能说出它的目标和主要挑战

能按顺序写出 8 个步骤

能给每一步举一个例子

能分清 discovery / collection / pre-processing / cleaning / transformation / enrichment / validation / storing

知道 subsetting、sampling、normalization、standardization、discretization、binning 的区别

能在 Jupyter Notebook 里完成基础代码与 markdown 操作

能用 pandas 读入 CSV 并查看数据结构

会做基础缺失值处理

接下来怎么学

时间	建议
本周	把 Python / Jupyter 基础补齐
Week 2-4	跟上 wrangling 流程、regex、EDA
Week 5-6	开始为 Quiz 1 和 A1 做准备
Week 7 后	重点转向 parsing / cleansing / integrating

下阶段

Week 3 会开始更具体地碰到 regex / text handling；