Data Wrangling 数据规整

知识点总结

FIT5196 - Data Wrangling
Week 1 & 2 Core Concepts

📋 目录

1. 什么是 Data Wrangling?
2. 为什么要做 Data Wrangling?
3. 数据规整的挑战
4. Data Wrangling 八大任务流程
5. 编程环境 & 工具

📌 一、什么是 Data Wrangling?

“ 数据规整是将原始数据转换为可供分析使用的过程 ”

✅ 定义

- **包括**：获取、清洗、结构化、丰富数据，使其适合分析
- **本质**：数据分析前的关键准备步骤
- **转换过程**：Raw Data → Clean Data → Actionable Insights

✅ 目的

- 🎯 提高数据质量
- 🔍 简化访问
- 🔗 促进整合
- ⚡ 降低复杂度
- 📈 提升分析效率
- 💡 支持决策制定

📌 二、为什么要做 Data Wrangling?

“ 不经过数据规整，分析可能得出错误或无法执行的结论 ”

✅ 示例数据源

- **UCI 数据集**：census income、credit approval
- **社交媒体**：Twitter、Facebook 数据
- **百科全书**：Wikipedia 结构化数据
- **医疗影像**：CT 报告等原始数据

问题：格式不一、缺失严重、结构复杂

✅ 数据转换流程

```
Raw Data → Tidy Data → Actionable Insights
原始数据 → 整洁数据 → 可行动的洞察
```

目标： 从混乱的原始数据中提取有价值的知识产品

📌 三、数据规整的挑战

数据体量挑战

- **大数据时代**：每天产生 2.5 quintillion 字节的数据
- **处理难度**：传统工具无法有效处理大规模数据
- **存储与计算**：需要分布式系统和云计算支持

🎯 质量问题

- **缺失值**：数据不完整
- **错误值**：输入错误、系统故障
- **重复数据**：同一记录多次出现
- **格式不一致**：日期、货币、地址格式混乱

🔄 多源数据整合

- **格式多样**：JSON、XML、CSV、Excel、图片等
- **结构差异**：结构化 vs 半结构化 vs 非结构化
- **标准不一**：缺少统一的数据交换标准

⏰ 时间与技能挑战

- **耗时严重**：数据科学家 60% 的时间用于清洗和组织数据
- **技能要求高**：需掌握 Python、统计、NLP、数据库等
- **隐私与安全**：特别是医疗等敏感领域的合规要求

📌 四、Data Wrangling 八大任务流程

🔄 完整流程图

```
Data Discovery → Data Collection → Data Pre-processing
      ↓
Data Cleaning → Data Transformation → Data Enrichment
      ↓
Data Validation → Data Storing
```

1. 🔍 Data Discovery

- **目标**：找出可用的数据源
- **评估维度**：
  - 可访问性 (Accessibility)
  - 适用性 (Relevance)
  - 质量 (Quality)
  - 成本 (Cost)

2. 📥 Data Collection

考虑因素：

- 🎯 目标 (Objectives)
- 📊 格式 (Format)
- 📈 体量 (Volume)
- 🔒 隐私 (Privacy)
- 💰 预算 (Budget)
- ⏰ 时间 (Timeline)

3. ⚙ Data Pre-processing

- **子集选择**：筛选相关数据
- **抽样**：处理大数据集
- **格式转换**：统一数据格式
- **单位转换**：标准化度量单位
- **文本标准化**：处理编码、大小写等

4. 🧹 Data Cleaning

主要任务：

- 处理缺失值 (Missing Values)
- 识别异常值 (Outliers)
- 去除重复 (Duplicates)
- 修正格式不一致 (Format Inconsistencies)

5. 🔄 Data Transformation

📊 数值数据转换

- 归一化 (Normalization)
- 标准化 (Standardization)
- 聚合 (Aggregation)
- 离散化 (Discretization)
- 分箱 (Binning)

📝 文本数据转换

- 分词 (Tokenization)
- 词干化 (Stemming)
- 向量化 (Vectorization)
- 情感分析 (Sentiment Analysis)

🖼️ 图像数据转换

- 尺寸调整 (Resizing)
- 颜色空间转换 (Color Space Conversion)
- 旋转与翻转 (Rotation & Flipping)
- 加噪与增强 (Noise & Augmentation)

6. 🔧 Data Enrichment

- **整合数据源**：合并多个数据集
- **增加属性**：计算新的特征
- **时间维度**：添加时间序列信息
- **语义信息**：增强数据表达力

7. ✅ Data Validation

检查项目：

- 📏 准确性 (Accuracy)
- 🔄 一致性 (Consistency)
- 🧩 逻辑完整性 (Logical Completeness)
- 📊 范围限制 (Range Constraints)
- 📝 格式规范 (Format Standards)

8. 💾 Data Storing

存储考虑：

- 🏗️ 结构设计 (Schema Design)
- 🔒 安全性 (Security)
- 🗃️ 索引优化 (Indexing)
- 💾 备份策略 (Backup)
- 🔄 生命周期管理 (Lifecycle Management)

📌 五、编程环境 & 工具

编程语言：Python 3.12

核心优势：

- 语法简洁易学
- 丰富的数据处理库
- 强大的社区支持
- 跨平台兼容性

📚 常用 Python 库

- `pandas`：数据结构和处理
- `NLTK`：自然语言处理
- `BeautifulSoup`：HTML/XML 解析
- `scikit-learn`：数据挖掘与分析
- `scipy`：科学计算
- `numpy`：数值计算基础

🛠️ 推荐开发环境

主要选择：

- **Jupyter Notebook** - 交互式开发
- **Anaconda** - 完整的数据科学平台
- **Google Colab** - 云端免费 GPU 支持

其他工具：

- **VS Code** - 专业代码编辑器
- **PyCharm** - Python 集成开发环境

🎯 总结

Data Wrangling 是数据科学的基础，掌握其核心概念和流程对于：

- 🎯 **提升数据质量**
- ⚡ **加速分析过程**
- 💡 **支持决策制定**
- 🚀 **推动业务价值创造**

至关重要！

Thank You!

谢谢

Questions & Discussion

FIT5196 - Data Wrangling