Data Wrangling 案例研究

医疗数据实战演练

预测病人再入院（Patient Readmission）
FIT5196 - Data Wrangling

🎯 案例背景

目标： 建立一个预测模型，判断哪些病人在出院后 **30 天内可能再入院**

意义：

- 减少医疗成本
- 提升护理质量
- 优化资源配置

第一步：🔍 Data Discovery

数据发现

📊 问题：数据源识别

假设你是医院数据分析团队成员，你有哪些可能的数据来源可以使用？（多选）

A. 电子病历（EHR）
B. 医保索赔数据
C. 病人佩戴的手环数据（可穿戴设备）
D. 医生的主观经验描述
E. 健康史 & 药物记录

✅ 答案：全部可用 (A~E)

数据源	包含内容	作用
电子病历（EHR）	诊断、用药、检验结果	识别既往病史和治疗效果
医保索赔数据	就诊、费用、报销记录	分析经济负担和医疗频率
可穿戴设备数据	心率、运动、睡眠等	分析恢复情况和生活习惯
医生描述	主观印象、注意事项	加入非结构化文本特征（NLP）
健康史与药物记录	慢病情况、长期用药	评估基础健康风险

第二步：📥 Data Collection

数据收集

📊 问题：关键因素识别

在收集 EHR 数据时，我们要特别注意哪三项 **关键因素**？
从以下选项中挑出最重要的三个：

A. 数据格式（如 CSV、JSON）
B. 法律合规与隐私保护（如 HIPAA）
C. 数据字段是否统一命名
D. 项目预算
E. 是否包含关键字段（出院时间、诊断码等）

✅ 答案：B、C、E

关键因素	原因
B. 法律合规与隐私保护	医疗数据高度敏感，必须合法合规处理
C. 字段命名和一致性	数据来自不同医院/系统，字段可能不统一，需统一
E. 是否包含关键字段	必须有"再入院"标签才能训练预测模型

第三步：🛠️ Data Pre-processing

数据预处理

📊 问题：识别预处理需求

以下是一份出院记录数据样本：

```
patient_id, Discharge_Date, Diagnosis, Readmitted, Age, Gender
P001, 12-03-2024, 心衰, Yes, 67, M
P002, 03/10/2024, Asthma, No, 54, Female
P003, 2024.05.28, Diabetes, YES, 60, F
```

这个数据有什么需要预处理的地方？
说出两个你注意到的问题。

✅ 答案：格式不一致问题

🧼 问题 1：列值不一致

- `Gender` 中有 `M` 和 `Female`
- `Readmitted` 有 `Yes` 和 `YES`

解决方案： 统一为标准格式

- `gender`: `male` / `female`
- `readmitted`: `yes` / `no`

📅 问题 2：日期格式混乱

- `12-03-2024` / `03/10/2024` / `2024.05.28`

解决方案： 统一为 `YYYY-MM-DD` 格式

第四步：🧹 Data Cleaning

数据清洗

📊 问题：区分清洗操作

哪些属于清洗操作，而不是预处理或转换？（多选）

A. 删除重复的病人记录
B. 把"YES"改成"yes"
C. 把 `Age` 的缺失值填为平均年龄
D. 把"心衰"翻译成"Heart Failure"
E. 把 `Gender` 列转换成 0/1 数值

✅ 答案：A、B

选项	属于清洗吗?	原因
✅ A. 删除重复记录	是	清理重复值，避免偏差
✅ B. 标准化 "YES" → "yes"	是	统一分类标签，避免误判
🔸 C. 缺失值填补	不完全	更偏向"预处理"或"修复"阶段的策略性操作
❌ D. 翻译成英文	否	属于"数据转换"或"语义统一"
❌ E. 类别转数值	否	这是"数据转换"常用做法（如编码、映射）

第五步：🔄 Data Transformation

数据转换

📊 问题：数值转换识别

我们需要把 `Age` 字段处理为模型更易接受的形式。
以下哪几种处理方式属于"数值转换"？（多选）

A. 标准化为 Z-score（均值为 0，标准差为 1）
B. 转成年龄段（如 50-59，60-69）
C. 正规化到 0~1 之间
D. 按年龄生成 "青年""中年""老年"三个标签
E. 替换为出生年份

✅ 答案：A、C

选项	是否数值转换?	理由
✅ A. Z-score 标准化	是	经典的数值变换，适用于线性模型
✅ C. 0~1 正规化	是	属于 Min-Max scaling，也是数值转换
🔸 B. 年龄段划分	有争议	更像是"离散化"或"分箱"，用于简化特征
❌ D. 青年/中年/老年	否	属于"语义分类"或"标签化"
❌ E. 替换为出生年份	否	虽然还是数字，但引入了新含义，是"衍生特征"

第六步：🔧 Data Enrichment

数据增强

📊 问题：特征扩展

如果我们想 enrich "药品使用记录"，我们可以从哪些公开数据或文档中**补充有用信息**?

例如： 药品名 → ?

说一个例子即可。

✅ 答案：药品分类信息

药品种类（例如：降压药、抗生素、镇痛药） 是非常实用的 enrich 信息。

🧬 药品信息 Enrichment 示例

原始字段	Enriched 字段	说明
`Drug_Name = "Metformin"`	`Drug_Type = "Antidiabetic"`	对分类模型更有帮助
`Drug_Name = "Atorvastatin"`	`Target_Organ = "Cardiovascular"`	可用于主题分析
`Drug_Name = "Ibuprofen"`	`OverTheCounter = true`	判断病人是否常依赖非处方药

数据来源： 药典数据库、药品编码系统（如 ATC code）、政府医疗指南

📦 地理位置信息扩展示例

从 **Postcode** 可扩展出的新特征：

衍生字段	来源	作用
Suburb	地址库	细化地理位置，利于地图可视化
State / Region	邮编对照表	用于政策/医疗覆盖范围分析
人口密度	人口普查数据	分析城市 vs 郊区患者的差异
平均收入水平	ABS (澳洲统计局)	社经状态与再入院率关联
医院距离	GIS 地理系统	距离远近是否影响复诊率

第七步：✅ Data Validation

数据验证

📊 问题：验证操作识别

以下哪些操作属于"数据验证"？（多选）

A. 检查 `Age` 是否都在 0~120 之间
B. 删除空值行
C. 确认 `patient_id` 无重复
D. 用医生手工标注验证模型输出
E. 检查 `Discharge_Date` 不晚于 `Readmit_Date`

✅ 答案：A、B、C、E

选项	属于验证吗?	说明
✅ A. 值范围检查	是	避免不合逻辑值影响结果
✅ B. 删除空值行	是	关键字段不能为空
✅ C. 唯一性检查	是	主键校验，防止混淆
✅ E. 逻辑一致性	是	保证时间顺序合理
❌ D. 人工验证模型输出	否	属于"模型评估"或"标注质量检查"

第八步：💾 Data Storing

数据存储

存储考虑因素：

- 🏗️ 结构设计 (Schema Design)
- 🔒 安全性 (Security)
- 📇 索引优化 (Indexing)
- 💾 备份策略 (Backup)
- 🔄 生命周期管理 (Lifecycle Management)

🧠 总结复习卡

DW 任务全流程

步骤	关键词	技巧点
1. 发现 Discovery	多源识别	判断可访问性、字段质量
2. 收集 Collection	隐私、格式、字段覆盖	合法合规收集重要特征
3. 预处理 Preprocess	格式、子集、抽样	统一格式，减小数据量
4. 清洗 Cleaning	缺失、重复、异常值	保障数据可靠
5. 转换 Transform	标准化、词向量、分箱	转换为模型友好结构
6. 增强 Enrichment	加字段、补语义	更丰富地反映现实
7. 验证 Validation	规则、范围、唯一性	检查可用性
8. 存储 Storing	结构设计、备份、安全	保证后续查询和分析可持续

Thank You!

谢谢

Data Wrangling 案例研究完成

Questions & Discussion
FIT5196 - Data Wrangling