📚 FIT5196 Week 9 Tutorial

Data Transformation 数据转换

补习班课程 - 重点知识梳理

回顾：Data Wrangling Tasks

- **数据预处理阶段 (Data Pre-processing)**：对原始数据进行准备，使其更适合后续分析。
- **上周内容**：Data Cleaning → 处理缺失值、异常值。
- **整体流程**：数据发现 → 数据收集 → 数据存储 → 数据清洗 → 数据验证 → 数据转换 → 数据增强。

Data Transformation 概述

- **定义**：清理并转换原始数据，使其更适合分析。
- **目标**：确保数据处于可用、有效率的格式，让分析更简单、更可靠。

涵盖内容：

- Data Normalisation（数据标准化）
- Data Discretisation（数据离散化）
- Data Construction（数据构造）
  - Feature Engineering（特征工程）
  - Data Sampling（数据采样）

Scaling 缩放

Min-Max Scaling

- Formula:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- ⚡ Maps to [0,1], sensitive to outliers.
- ⚡ 映射到 [0,1]，对异常值敏感。

MaxAbs Scaling

- Formula:

$$x' = \frac{x}{\max(|x|)}$$

- ⚡ Keeps sign, scales to [-1,1].
- ⚡ 保留符号，缩放到 [-1,1]。

Decimal Scaling

- Move decimal point by factor 10^j until max(|x|)<1.
- ⚡ Simple rescaling via decimal shift.
- ⚡ 通过小数点移动缩放。

Robust Scaling

- Formula:

$$x' = \frac{x - \text{median}(x)}{\text{IQR}}$$

- ⚡ Resistant to outliers.
- ⚡ 对异常值鲁棒。

Log Scaling

- Formula:

$$x' = \log(x)$$

- ⚡ Reduces skew, spreads small values.
- ⚡ 减少偏态，展开小数值。

2. Standardisation 标准化

Z-score Normalisation

- Formula:

$$z = \frac{x - \mu}{\sigma}$$

- ⚡ Mean=0, Std=1, assumes Gaussian.
- ⚡ 均值=0，标准差=1，适合正态分布算法。

3. Transformation 变换

Linear Transformation

- Add constant (shift) or multiply constant (scale).
- ⚡ Simple shift/scale of data.
- ⚡ 简单平移/缩放数据。

Power Transformation (Box-Cox)

- Formula:

$$y = \begin{cases} \frac{x^{\lambda}-1}{\lambda}, & \lambda \neq 0 \\ \log(x), & \lambda = 0 \end{cases}$$

- ⚡ Makes data closer to normal distribution.
- ⚡ 使数据更接近正态分布。
- **要求**：输入 $x > 0$，因为对数和幂函数在负数上不定义。
- **作用**：找到合适的 λ，把数据分布拉近正态分布。
- **特点**：只能处理严格正的连续变量（比如价格、年龄、收入）。

解决办法：取极限

当 $\lambda \to 0$ 时，可以用 **洛必达法则** 来算极限：

$$\lim_{\lambda \to 0} \frac{x^{\lambda} - 1}{\lambda} = \log(x)$$

所以当 $\lambda = 0$ 时，Box-Cox 变换就自然退化成了 **对数变换**。

- **连续性：**
  这样定义后，Box-Cox 变换在不同 λ 值下是 **连续平滑的**，不会在 $\lambda = 0$ 出现“断点”。
- **灵活性：**
  - 当 $\lambda = 1$：就是线性变换（不变）。
  - 当 $\lambda = 0$：就是对数变换。
  - 当 $\lambda = 0.5$：是平方根变换。
  - 当 $\lambda = -1$：是倒数变换。
- **统一框架：**
  Box-Cox 可以看作一个“超集”，不同 λ 对应不同常见变换（log、sqrt、reciprocal 等），不需要单独写多个公式。

⚡ **一句话总结：**

Box-Cox 用两种情况（$\lambda \neq 0$ 和 $\lambda = 0$）是为了避免除零，同时保证变换在 $\lambda = 0$ 处连续，把 **对数变换**纳入同一个统一框架里。

Box-Cox with Negatives

- Formula with offset c and scale g.
- ⚡ Shift negatives (c), scale (g), optimise λ.
- ⚡ 通过 c 平移负值，g 缩放，λ 搜索最佳正态化。

$$y = \begin{cases} \frac{(x+c)^{\lambda}-1}{g\lambda}, & \lambda \neq 0 \\ \frac{\log(x+c)}{g}, & \lambda = 0 \end{cases}$$

- **新增参数**：
  - c：把负数/零整体平移为正（offset）。
  - g：缩放因子，常取几何均值（geometric mean），避免数值过大或过小。
- **作用**：可以在原始数据包含 **负值** 或 **0** 的情况下仍能使用 Box-Cox。
- **好处**：更灵活，不会因为数据里有负数就没法用。

Box-Cox 版本	输入要求	新增参数	适用场景
基础版	$x > 0$	无	适合自然正数（价格、销量等）
扩展版（带 c, g）	$x + c > 0$	偏移 c、缩放 g	可处理负数、0、不同量纲数据

⚡ **一句话总结：**

- **基础版 Box-Cox** 只能处理正数变量；
- **扩展版 Box-Cox** 通过平移 c 和缩放 g 扩展到负数场景，更通用。